神经网络
Neural Network

深度学习三次热潮

第一次热潮(20世纪50-60年代)

- 1950年图灵提出了图灵测试。
- 1958年计算机科学家Rosenblatt提出了一种具有三层网络特性的神经网络结构，成为“感知器”。
- 1969年，人工智能的先驱Minsky出版了一本名为《感知器》的书，书中指出简单的神经网络只能运用于线性问题的求解，能够求解非线性问题的网络应具有隐层，而从理论上还不能证明将感知器扩展到多层网络是有意义的。

第二次热潮(20世纪80-90年代)

- 语音识别是当时最具代表性的突破成果之一，语音识别领域最具代表性的人物就是李开复了。
- 1986年，Rumelhart，Hinton，Williams发展了BP算法。（多层感知器的误差反向传播算法）。
- 1987年6月，首届国际神经网络学术会议在美国加州圣地亚哥召开，到会代表有1600余人。之后国际神经网络学会和国际电气工程师与电子工程师学会（IEEE）联合召开每年一次的国际学术会议。

第三次热潮(2006年至今)

- 2006年Hinton在《Science》杂志上的发表了一篇深度学习的论文。
- 2009年李飞飞创立ImageNet。
- 2016年AlphaGo战胜人类顶级围棋选手。

深度学习爆发三要素

ImageNet Dataset

Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., ... & Fei-Fei, L. (2015). Imagenet large scale visual recognition challenge. *arXiv preprint arXiv:1409.0575.* [web]

ILSVRC

ImageNet Challenge

IMAGENET

- 1,000 object classes (categories).
- Images:
  - 1.2 M train
  - 100k test.

4

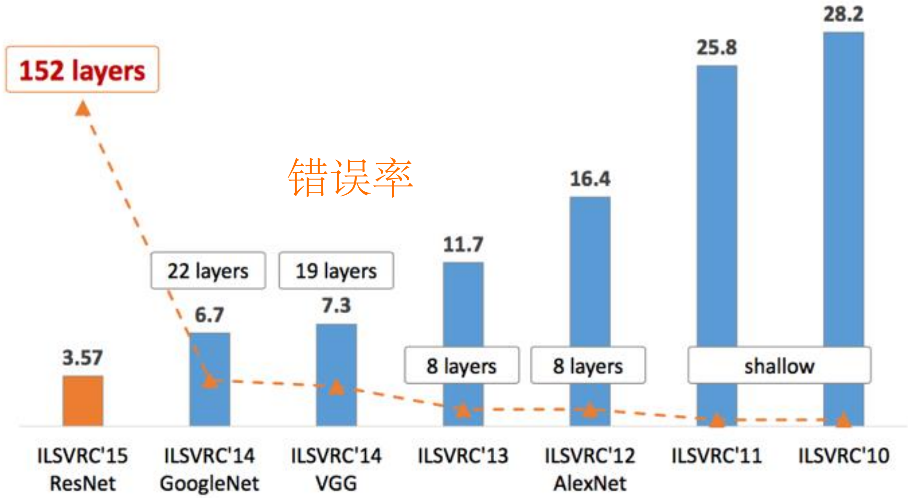

计算能力

GPU

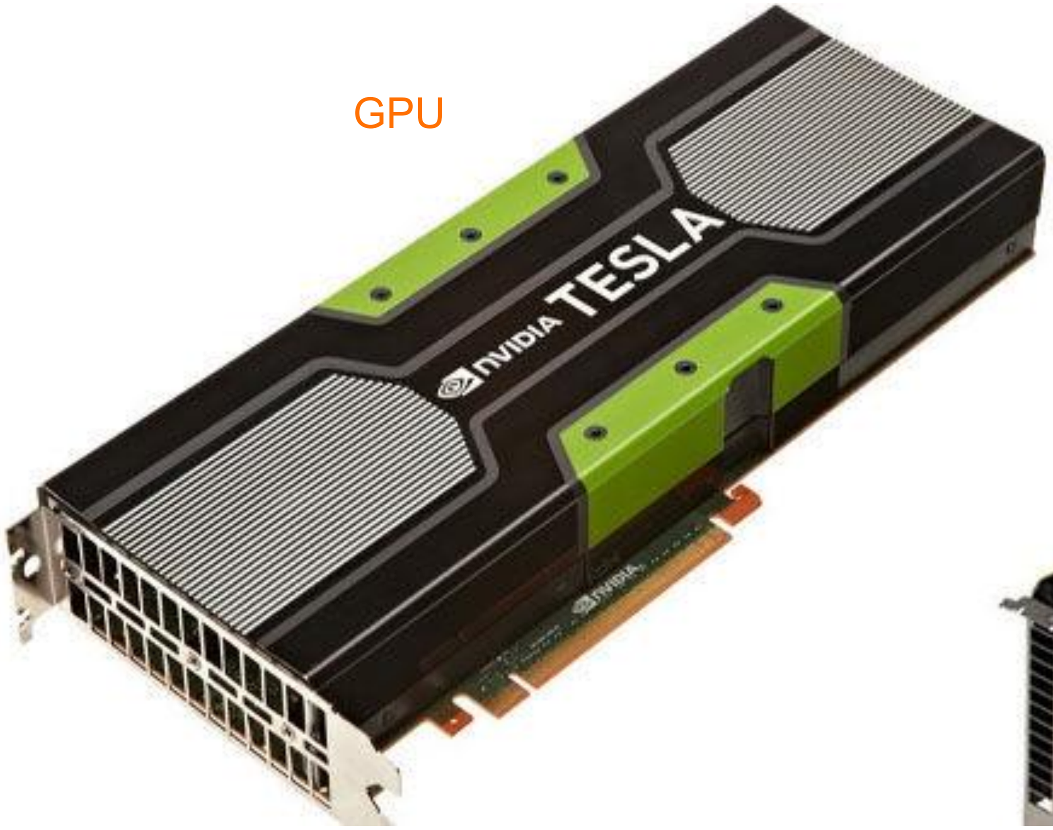

算法

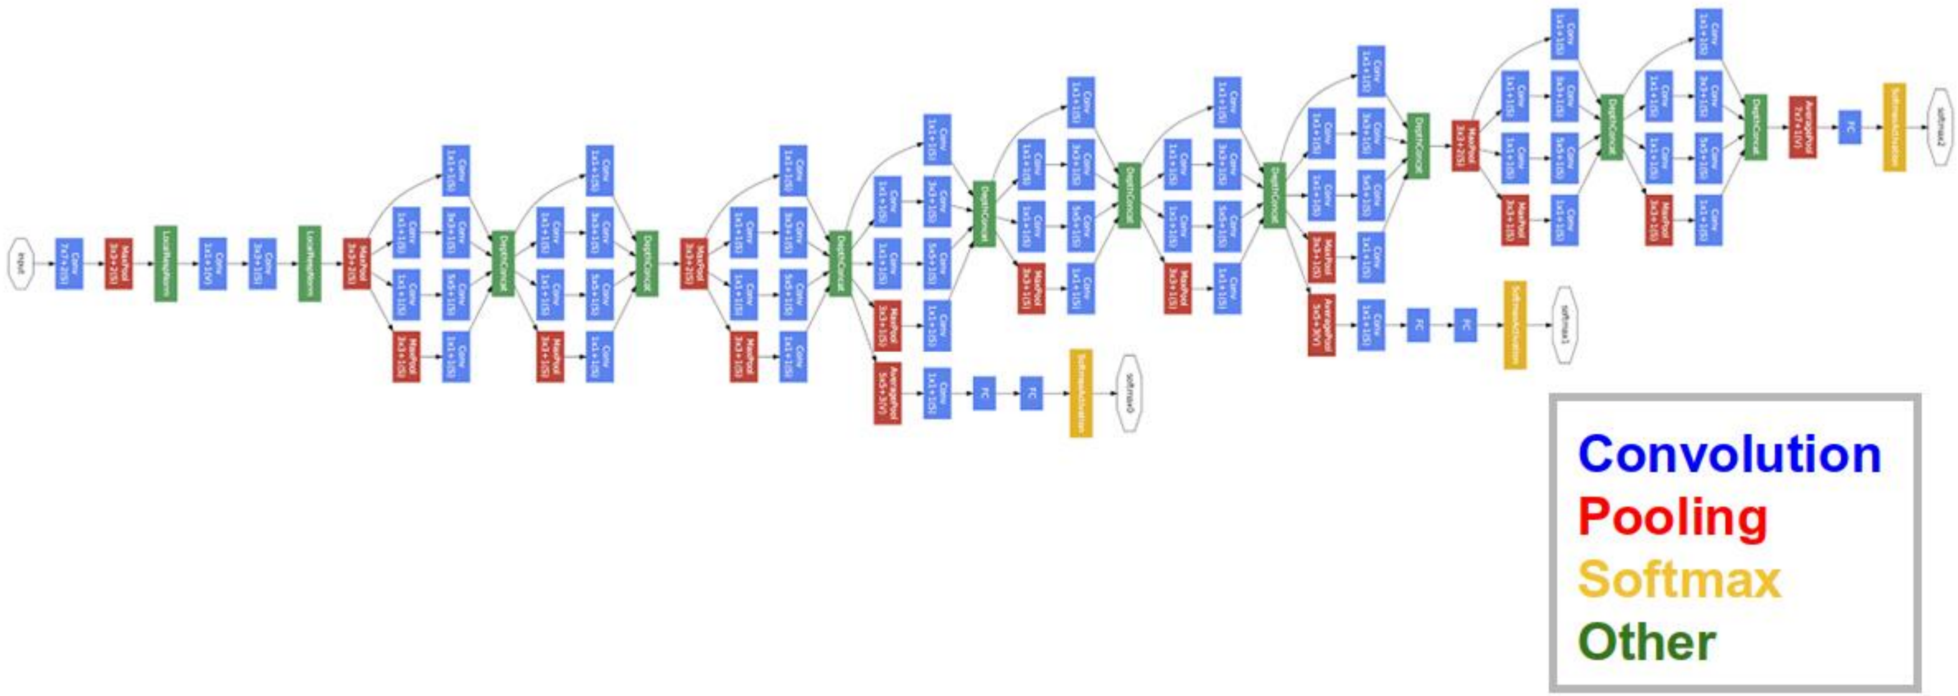

深度学习三巨头

Geoffrey Hinton

- 英国出生的计算机学家和心理学家，以其在神经网络方面的贡献闻名。Hinton是反向传播算法的发明人之一，也是深度学习的积极推动者。目前担任多伦多大学计算机科学系教授。
- 2013年3月加入Google，领导Google Brain项目。

Yann LeCun

- 计算机科学家，他最著名的工作是光学字符识别和计算机视觉上使用卷积神经网络（CNN），他也被称为卷积网络之父。

- 多伦多大学跟随Hinton做博士后。1988年，加入贝尔实验室，之后研发出了卷积神经网络，曾广泛用于手写数字识别。

- 2003年去了纽约大学任教。2013年12月加入了Facebook，成为Facebook人工智能实验室的第一任主任。

Yoshua Bengio

- 在MIT和贝尔实验室做过博士后研究员，自1993年之后就在蒙特利尔大学任教。在预训练和自动编码器等方面作出过重大贡献。

- “我留在学术圈为全人类作贡献，而不是为某一个公司赚钱”

Andrew Wu（吴恩达）

- 曾经是斯坦福大学计算机科学系和电气工程系的副教授，斯坦福人工智能实验室主任。他创建了在线教育平台Coursera。
- 2011年，吴恩达在Google创建了Google Brain项目，通过分布式集群计算机开发超大规模的人工神经网络。
- 2014年5月，吴恩达加入百度，负责百度大脑计划，并担任百度公司首席科学家。
- 2017年3月，吴恩达从百度离职。

关系图

LeCun Hinton Bengio Andrew Ng

单层感知器

人体神经网络

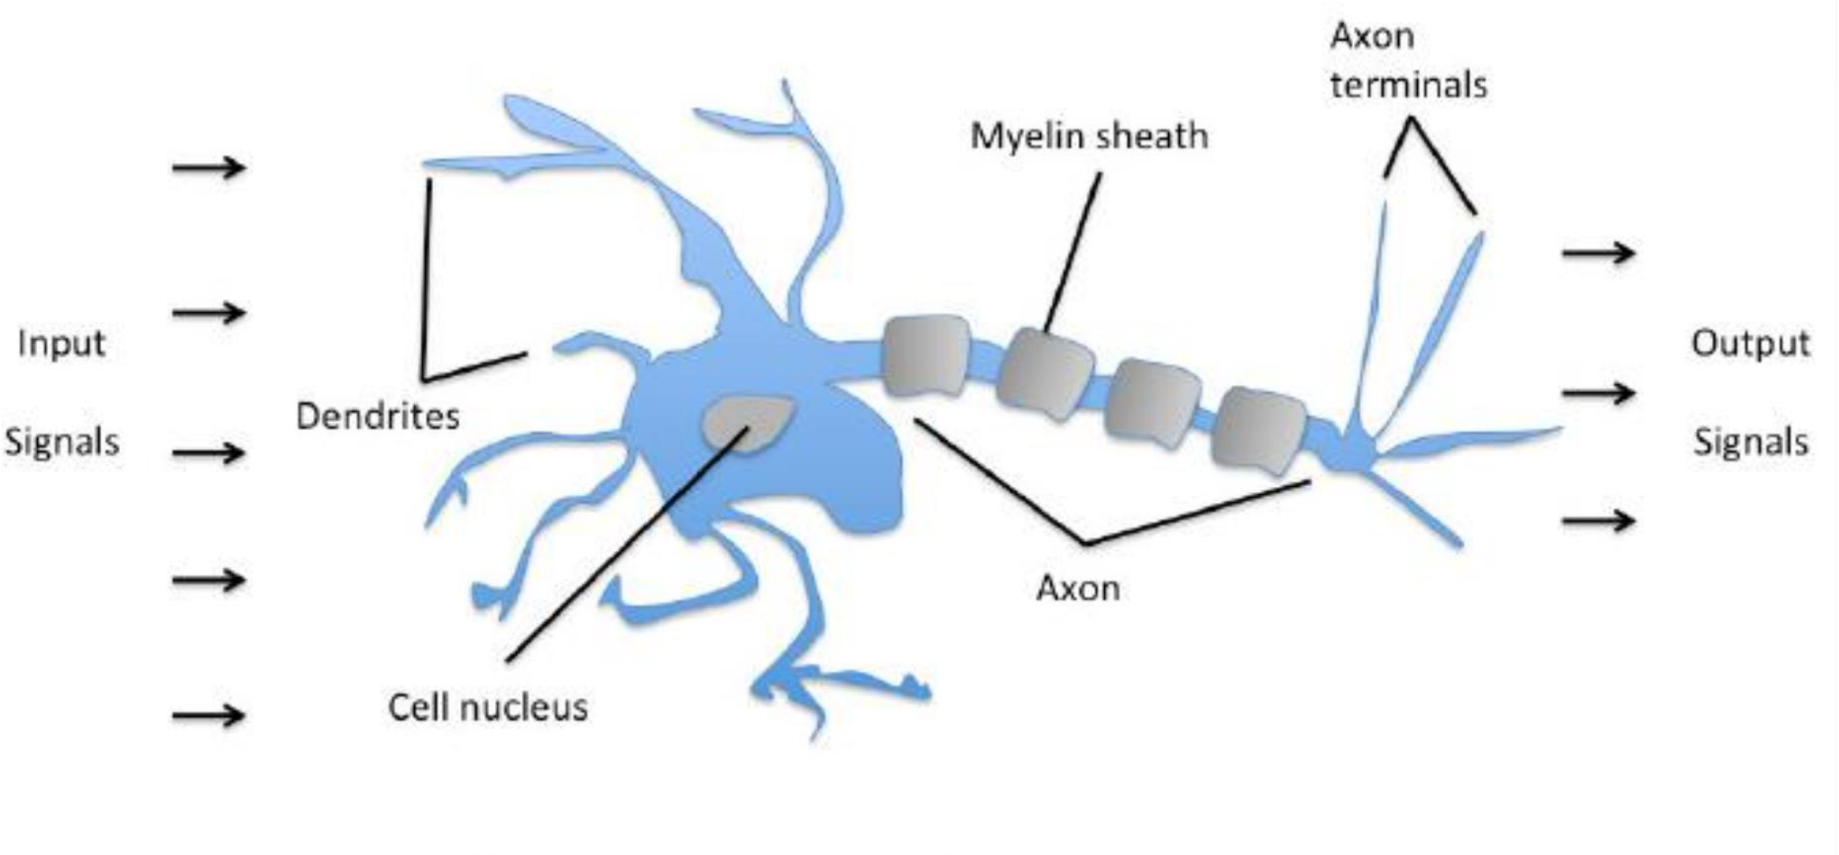

Schematic of a biological neuron.

单层感知器

输入节点：x_1,x_2,x_3

输出节点：y

权向量：w_1,w_2,w_3

偏置因子：b

激活函数：$\text{sign}(x)=\begin{cases}1 & X>=0\\ -1 & X<0\end{cases}$

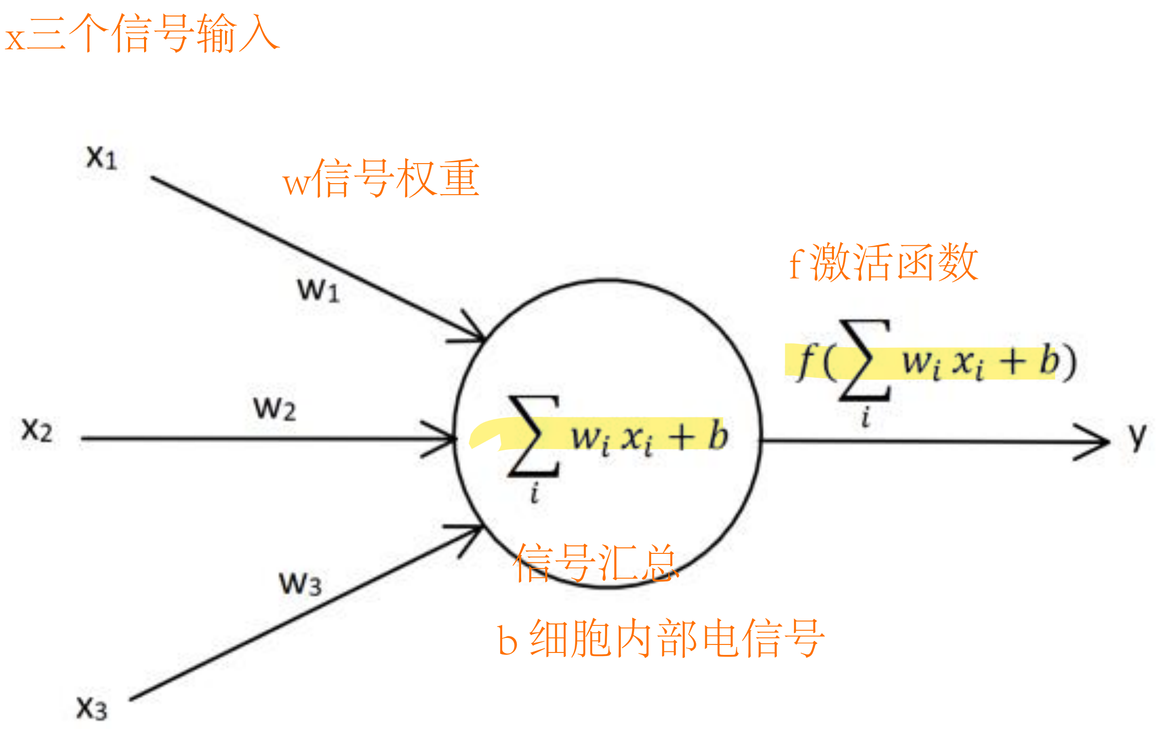

单层感知器举例

b=-0.6

x_1	x_2	x_3	Y
0	0	0	-1
0	0	1	-1
0	1	0	-1
0	1	1	1
1	0	0	-1
1	0	1	1
1	1	0	1
1	1	1	1

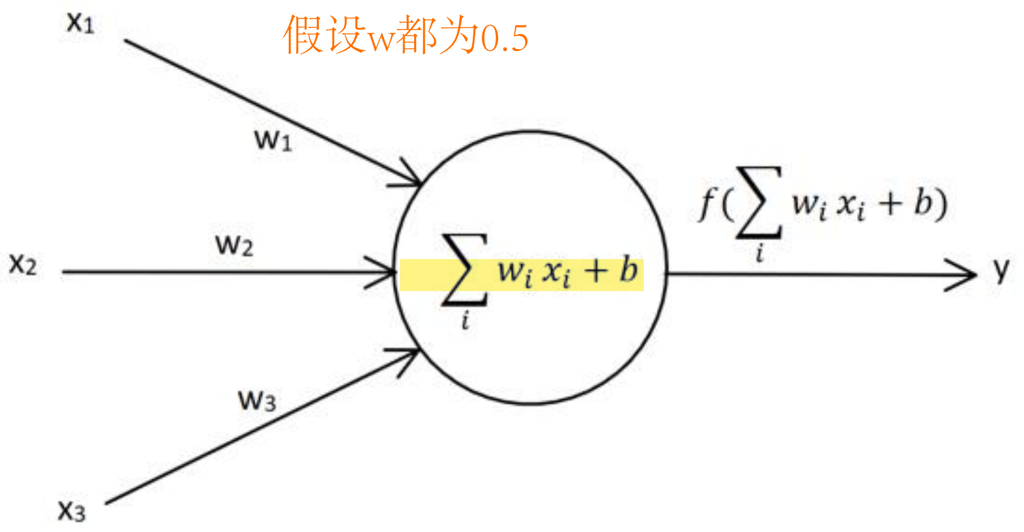

$$y = \begin{cases} 1 & (0.5x_1+0.5x_2+0.5x_3-0.6>=0) \\ -1 & (0.5x_1+0.5x_2+0.5x_3-0.6<0) \end{cases}$$

单层感知器

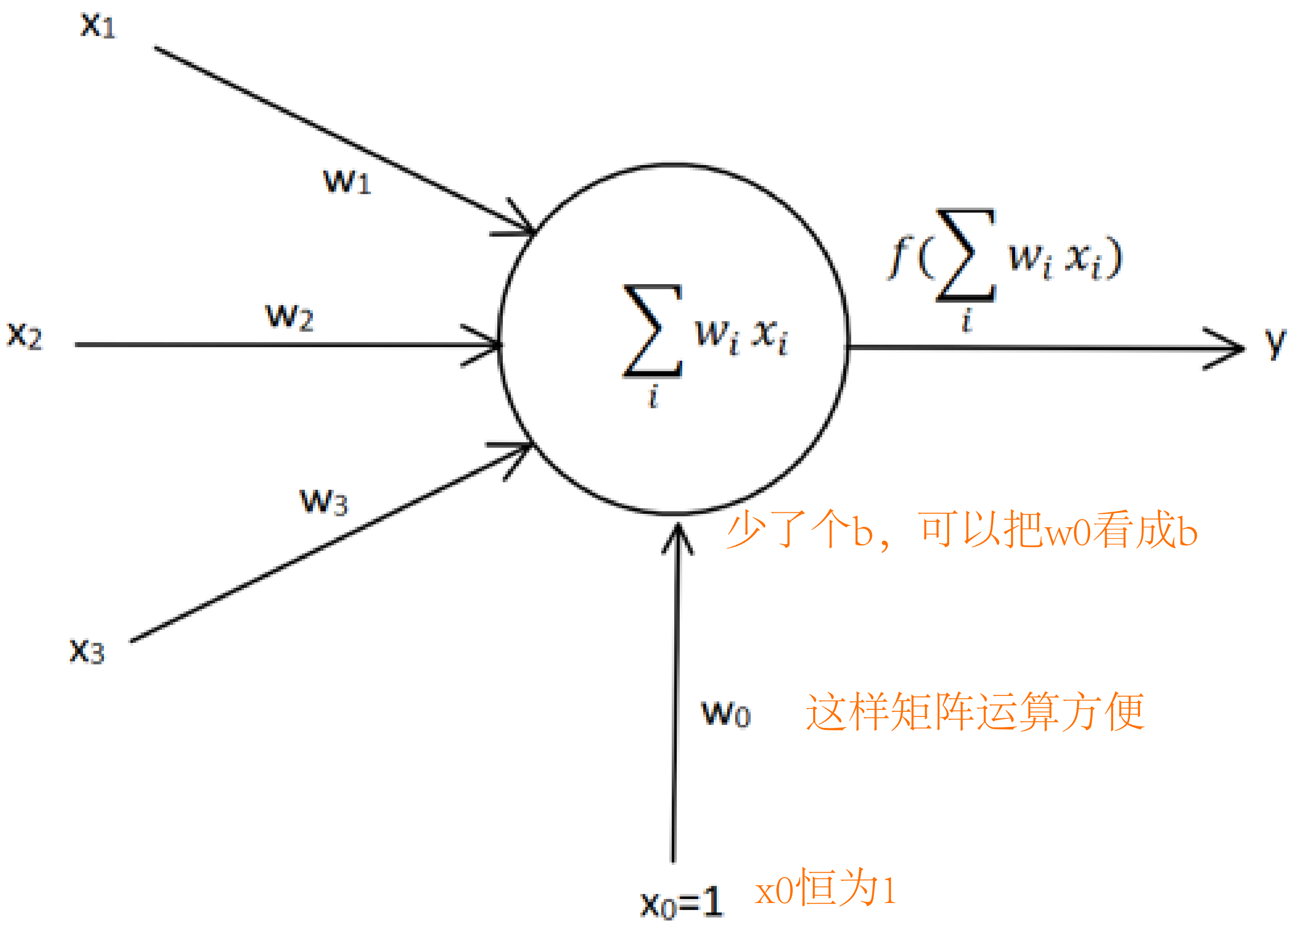

x_1
w_1
x_2
w_2
x_3
w_3
$\sum_i w_i x_i$
$f(\sum_i w_i x_i)$
y
少了个b，可以把w0看成b
w_0
这样矩阵运算方便
$x_0=1$
x0恒为1

感知器学习规则

$$y = f\left(\sum_{i=1}^{n} x_i \cdot w_i\right)$$

i = 0,1,2…
y是网络输出
f是sign函数 激活函数

$$\Delta w_i = \eta(t - y)x_i$$

η表示学习率
t表示正确的标签
t和y的取值为±1

进行分类

$$\Delta w_i = \pm 2\eta x_i$$

$$w_i = w_i + \Delta w_i$$

感知器学习规则

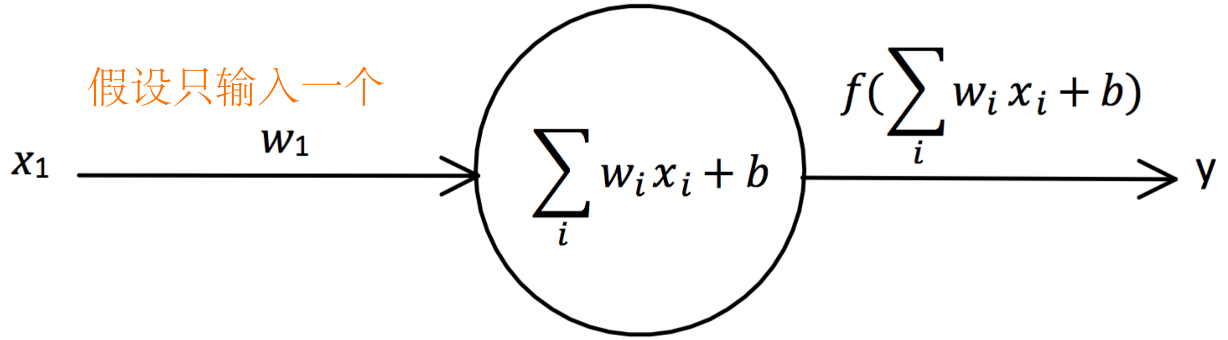

$$\Delta w_i = \eta(t - y)x_i$$

正确的标签，真实值

假设：t=1，η=1，x1=1，w1=-5，b=0:

Step1:	Step2:	Step3:
y = sign(1*(-5)) = -1	y = sign(1*(-3)) = -1	y = sign(1*(-1)) = -1
Δw = 1*(1-(-1))*1 = 2	Δw = 1*(1-(-1))*1 = 2	Δw = 1*(1-(-1))*1 = 2
w1 = w1 + Δw = -3	w1 = w1 + Δw = -1	w1 = w1 + Δw = 1
		y = sign(1*1) = 1 = t
		这时候预测值y才和真实值t相等，结束

学习率

η取值一般取0-1之间

学习率太大容易造成权值调整不稳定

学习率太小，权值调整太慢，迭代次数太多

不同学习率

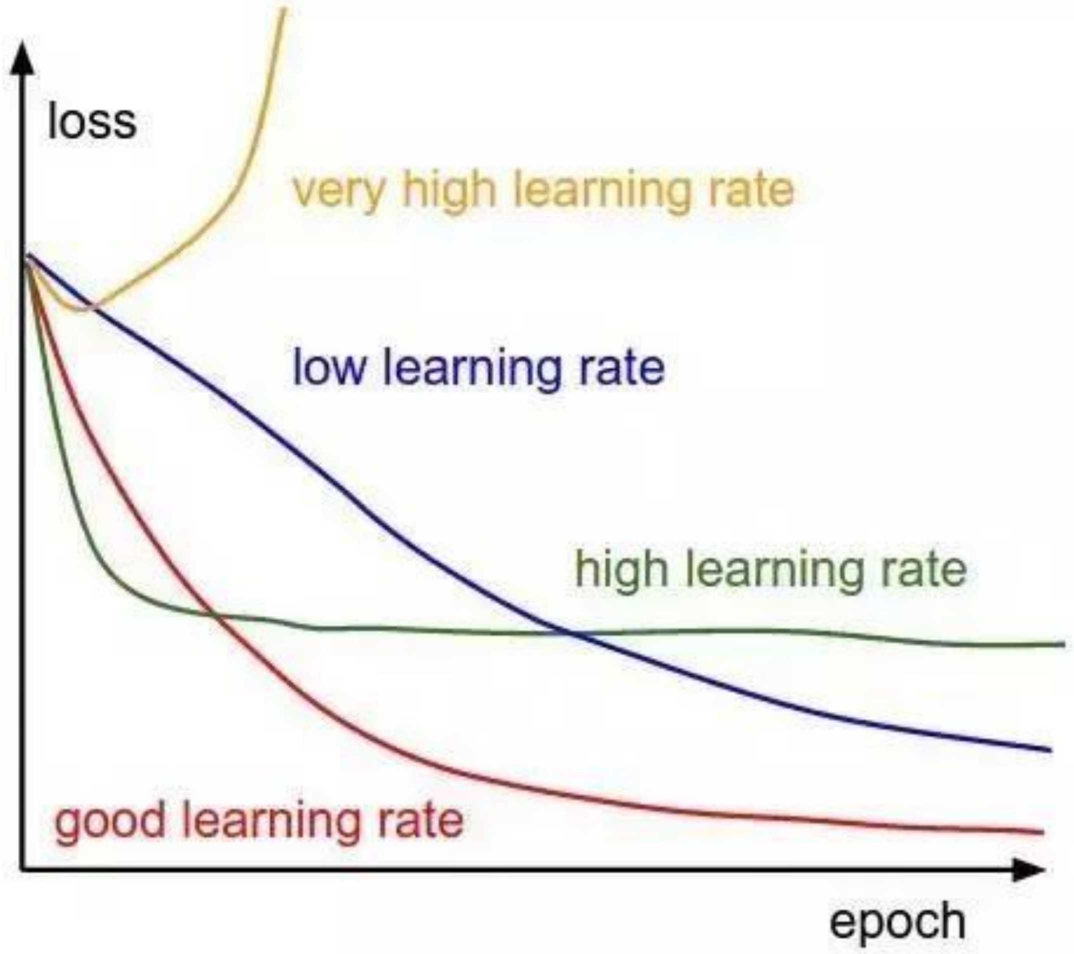

loss
very high learning rate
low learning rate
high learning rate
good learning rate
epoch

模型收敛条件

模型停止的三个条件

误差小于某个预先设定的较小的值

两次迭代之间的权值变化已经很小

设定最大迭代次数，当迭代超过最大次数就停止

单层感知器程序

题目：假设平面坐标系上有四个点，(3,3),(4,3)这两个点的标签为1，(1,1),(0,2)这两个点的标签为-1。构建神经网络来分类。

思路：我们要分类的数据是2维数据，所以只需要2个输入节点，我们可以把神经元的偏置值也设置成一个节点，这样我们需要3个输入节点。

第一个1是偏置值　　相当于多的一个维度

输入数据有4个(1,3,3),(1,4,3),
(1,1,1),(1,0,2)
数据对应的标签为(1,1,-1,-1)
初始化权值w_0,w_1,w_2取-1到1的随机数
学习率(learning rate)设置为0.11
激活函数为sign函数

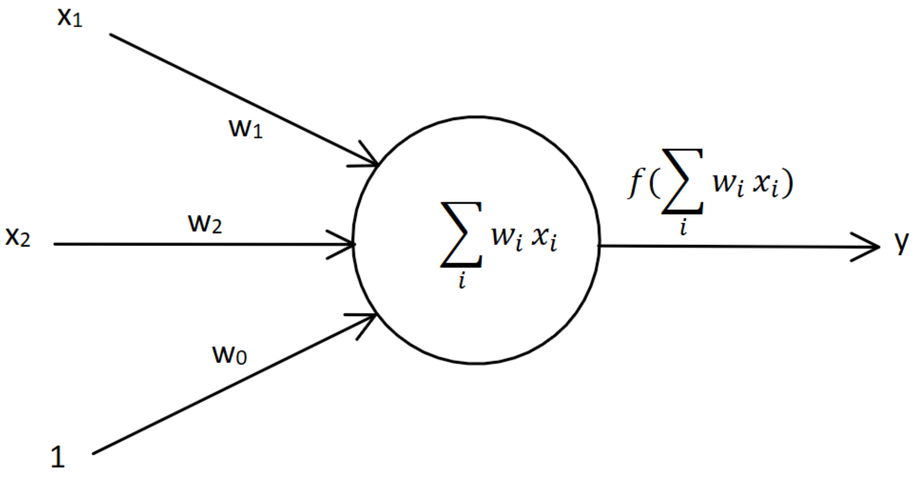

单层感知器分类

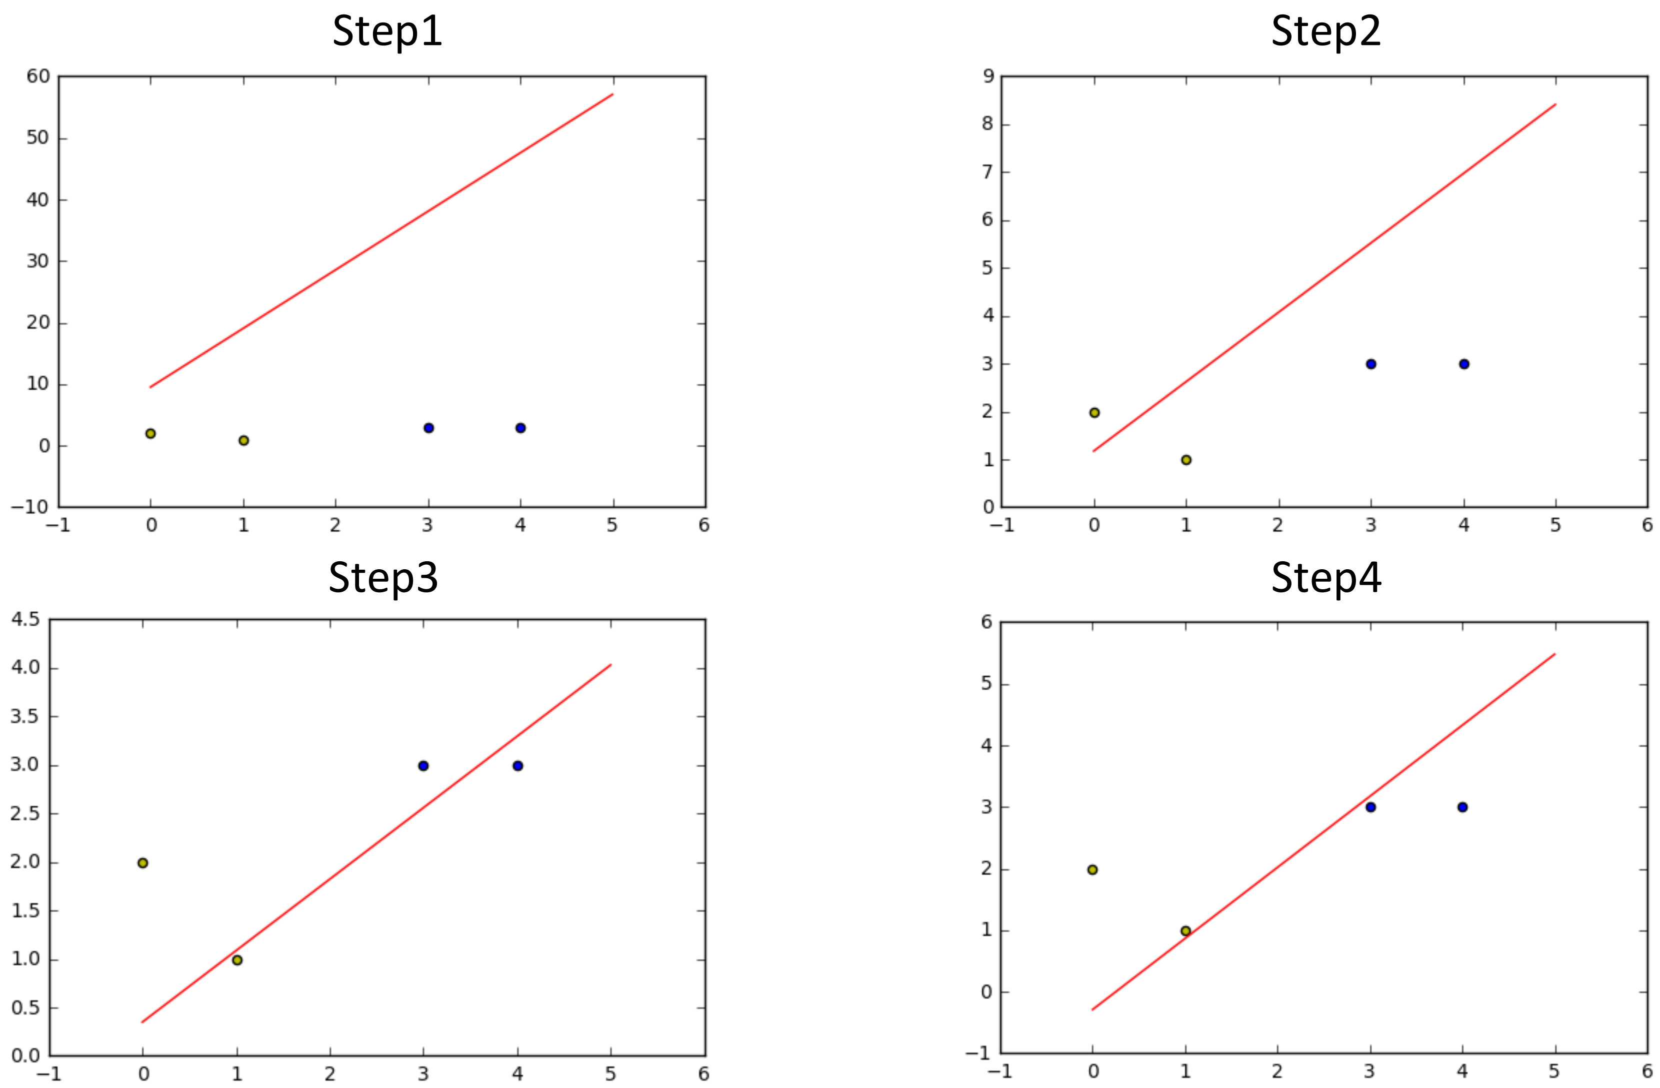

线性神经网络

线性神经网络在结构上与感知器非常相似，只是激活函数不同。
在模型训练时把原来的sign函数改成了purelin函数：y = x

新的激活函数

线性神经网络分类

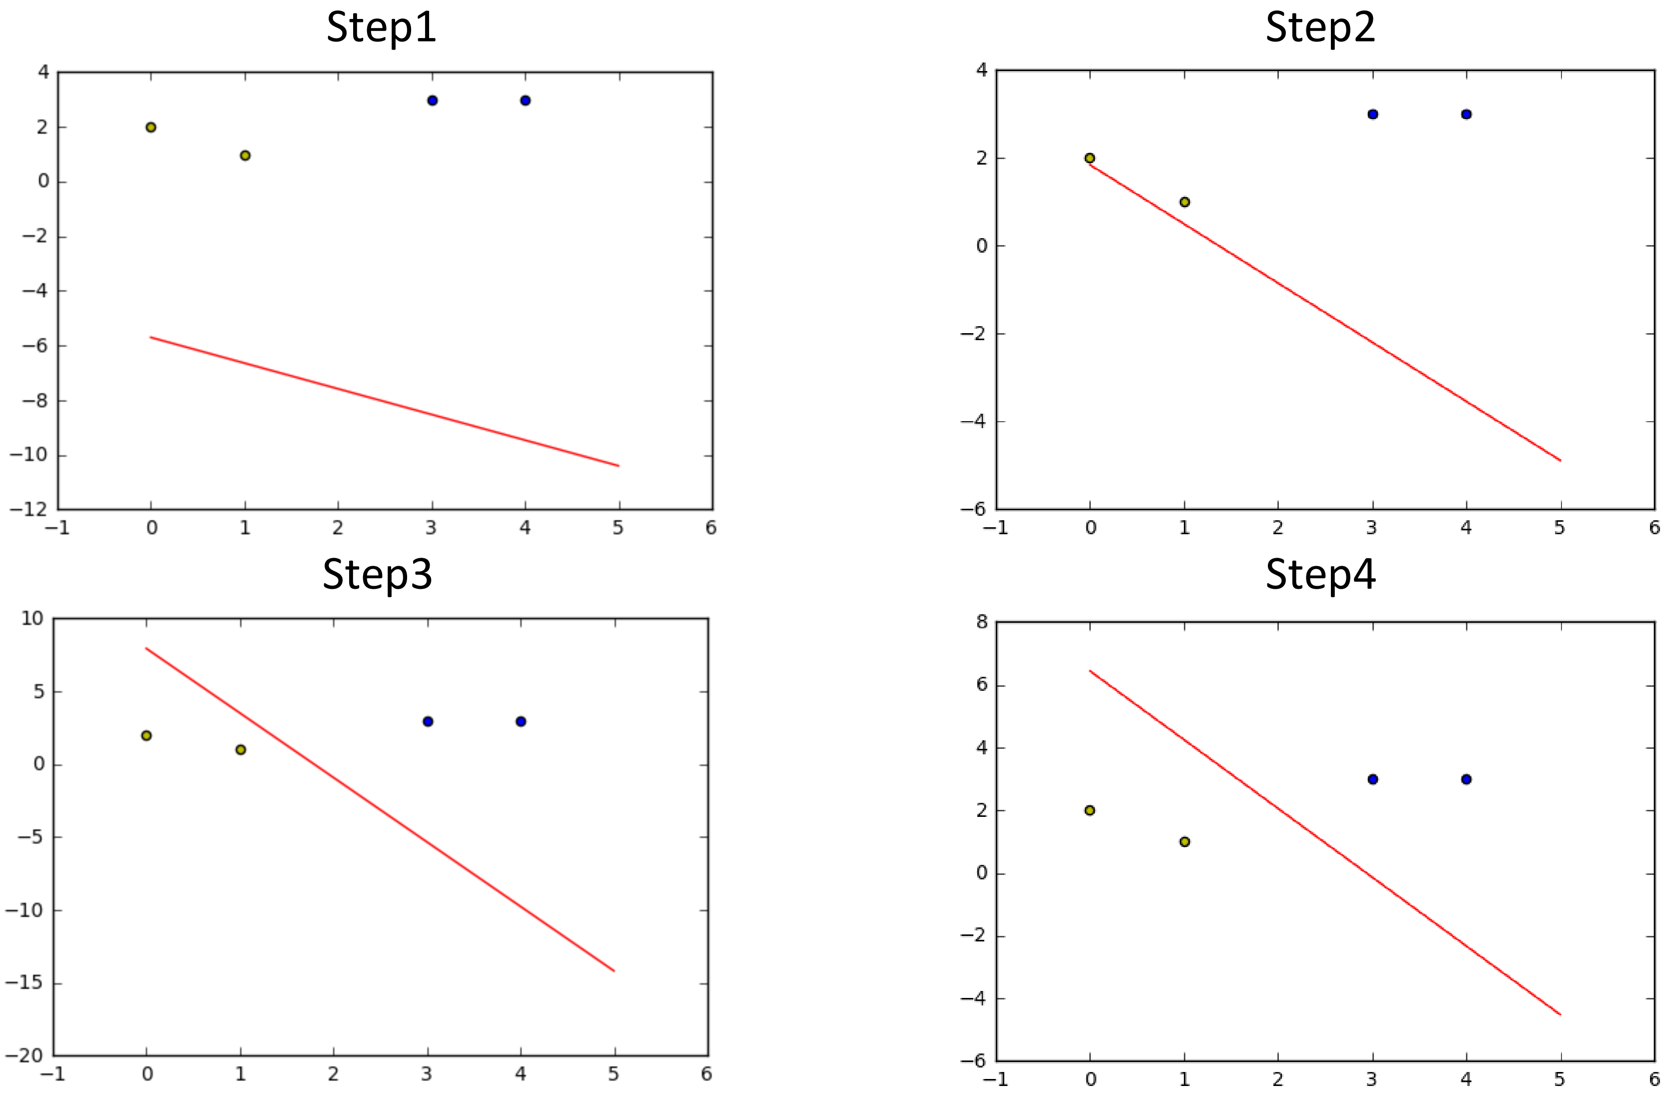

激活函数

Name	Plot	Equation	Derivative
Identity	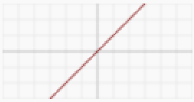	$f(x)=x$	$f'(x)=1$
Binary step	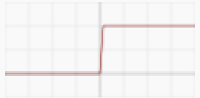	$f(x)=\begin{cases}0 & \text{for} \quad x<0\\ 1 & \text{for} \quad x\geq 0\end{cases}$	$f'(x)=\begin{cases}0 & \text{for} \quad x\neq 0\\ ? & \text{for} \quad x=0\end{cases}$
Logistic (a.k.a Soft step)	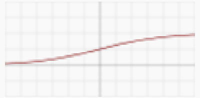	$f(x)=\frac{1}{1+e^{-x}}$	$f'(x)=f(x)(1-f(x))$
TanH	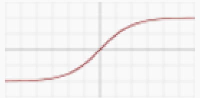	$f(x)=\tanh(x)=\frac{2}{1+e^{-2x}}-1$	$f'(x)=1-f(x)^2$
ArcTan	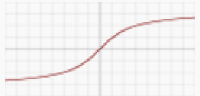	$f(x)=\tan^{-1}(x)$	$f'(x)=\frac{1}{x^2+1}$
Rectified Linear Unit (ReLU)	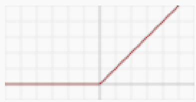	$f(x)=\begin{cases}0 & \text{for} \quad x<0\\ x & \text{for} \quad x\geq 0\end{cases}$	$f'(x)=\begin{cases}0 & \text{for} \quad x<0\\ 1 & \text{for} \quad x\geq 0\end{cases}$
Parameteric Rectified Linear Unit (PReLU)[2]	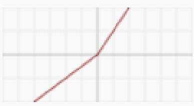	$f(x)=\begin{cases}\alpha x & \text{for} \quad x<0\\ x & \text{for} \quad x\geq 0\end{cases}$	$f'(x)=\begin{cases}\alpha & \text{for} \quad x<0\\ 1 & \text{for} \quad x\geq 0\end{cases}$
Exponential Linear Unit (ELU)[3]	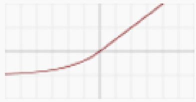	$f(x)=\begin{cases}\alpha(e^x-1) & \text{for} \quad x<0\\ x & \text{for} \quad x\geq 0\end{cases}$	$f'(x)=\begin{cases}f(x)+\alpha & \text{for} \quad x<0\\ 1 & \text{for} \quad x\geq 0\end{cases}$
SoftPlus	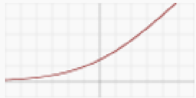	$f(x)=\log_e(1+e^x)$	$f'(x)=\frac{1}{1+e^{-x}}$

Delta学习规则

1986年，认知心理学家McClelland和Rumelhart在神经网络训练中引入了δ规则，该规则也可以称为连续感知器学习规则。

δ学习规则是一种利用梯度下降法的一般性学习规则。

和回归中 梯度下降法 一样

Delta学习规则

代价函数(损失函数)(Cost Function,Lost Function)

二次代价函数：

t实际值，y预测值

f(wx)神经网络的预测值

$$E = \frac{1}{2}(t-y)^2 = \frac{1}{2}[t-f(WX)]^2$$

误差E是权向量W的函数，我们可以使用梯度下降法来最小化E的值：

对E求导

$$\Delta W = -\eta E' = \eta X^T(t-y)f'(WX) = \eta X^T\delta$$

对W求导，把W看成变量

$$\Delta w_i = -\eta E' = \eta x_i(t-y)f'(WX) = \eta x_i\delta$$

梯度下降法-一维情况

$$w = w + \Delta w$$

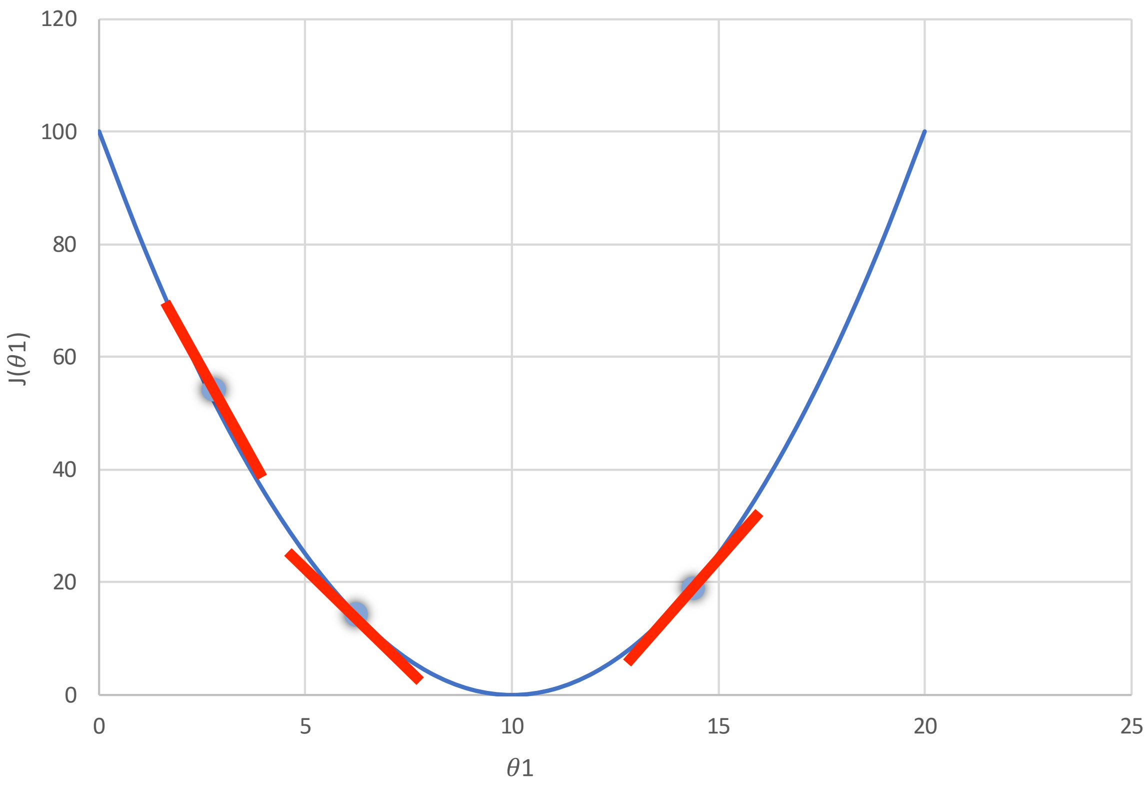

梯度下降法-二维情况

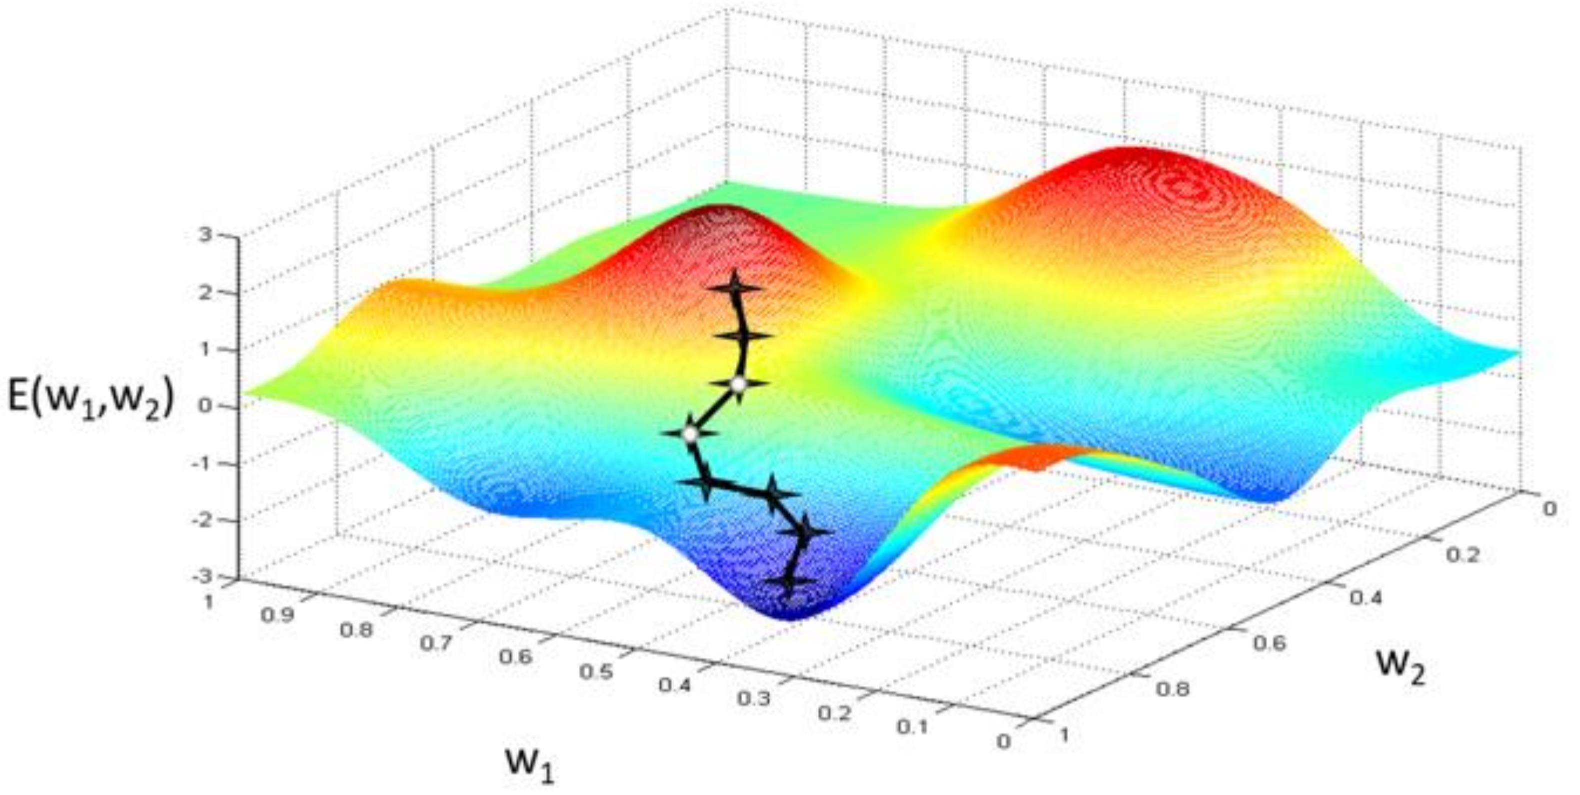

梯度下降法的问题

1.学习率难以选取，太大会产生震荡，太小收敛缓慢
2.容易陷入局部最优解(局部极小值)

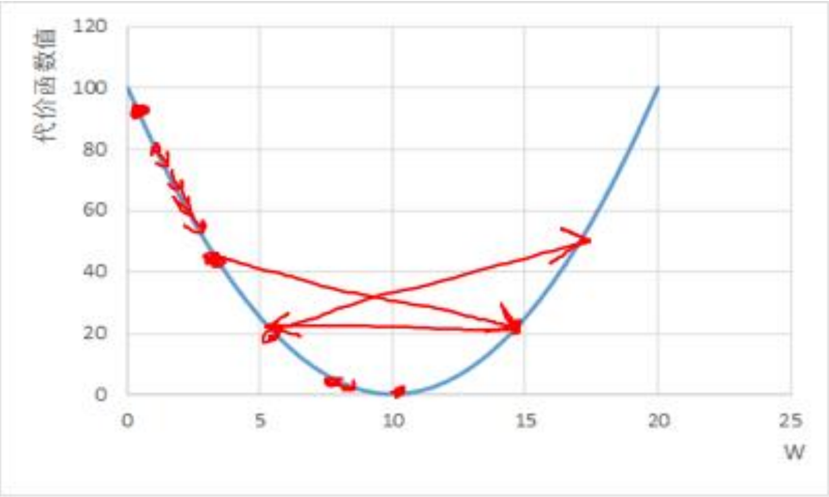

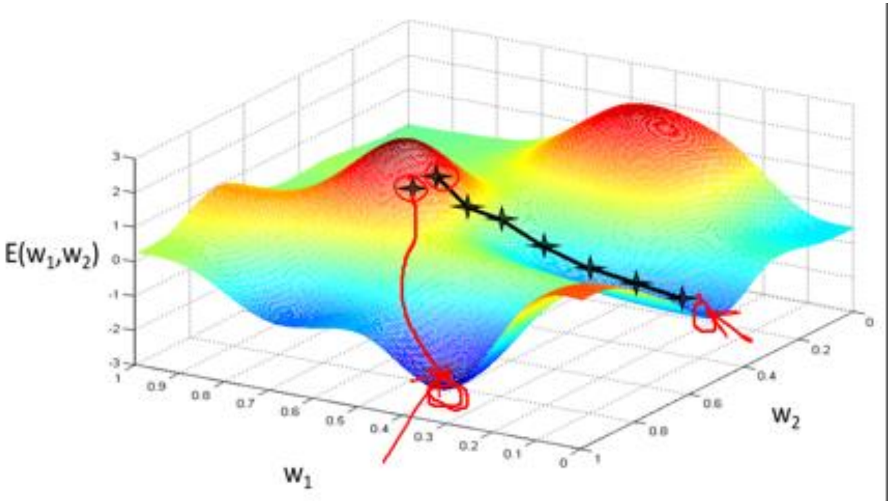

解决异或问题

Madaline 可以用一种间接的方式解决线性不可分的问题，方法是用多个线性函数对区域进行划分，然后对各个神经元的输出做逻辑运算。如图 5-3 所示，Madaline 用两条直线实现了异或逻辑。

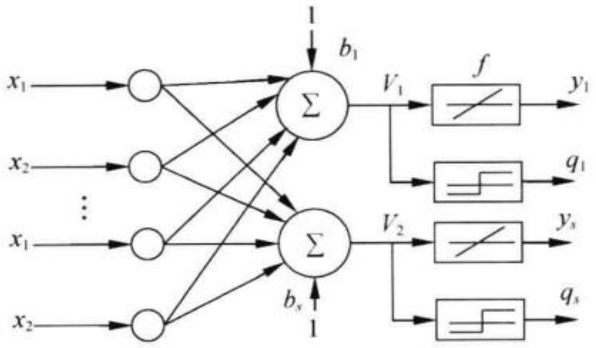

图 5-2　Madaline 结构图

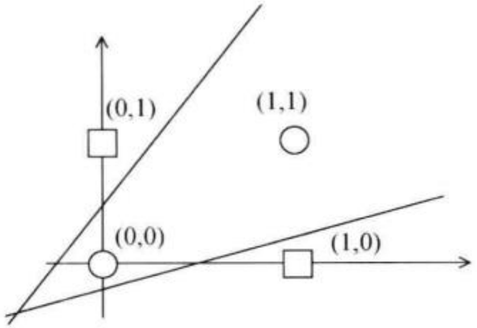

图 5-3　Madaline 实现异或

线性神经网络解决线性不可分问题的另一个方法是，对神经元添加非线性输入，从而引入非线性成分，这样做会使等效的输入维度变大，如图 5-4 所示。

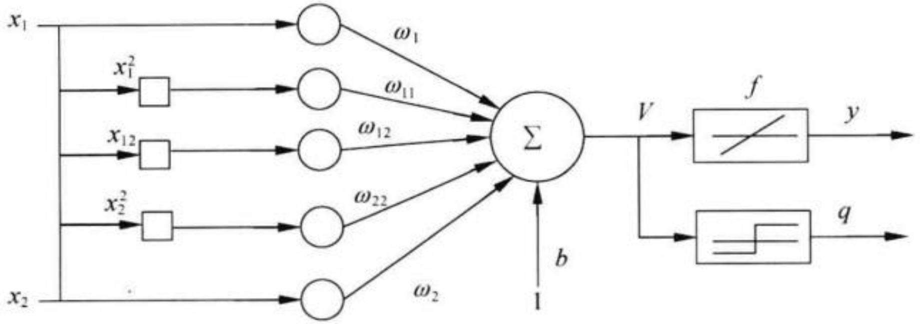

图 5-4　线性网络解决非线性问题

BP神经网络
Back Propagation Neural Network

BP(Back Propagation)神经网络

1986年，由McClelland和Rumelhart为首的科学家小组提出，解决了多层神经网络的学习问题，极大促进了神经网络的发展。

BP神经网络也是整个人工神经网络体系中的精华，广泛应用于分类识别，逼近，回归，压缩等领域。在实际应用中，大约80%的神经网络模型都采取了BP网络或BP网络的变化形式。

网络结构

此图一共三层，输入层一般不算

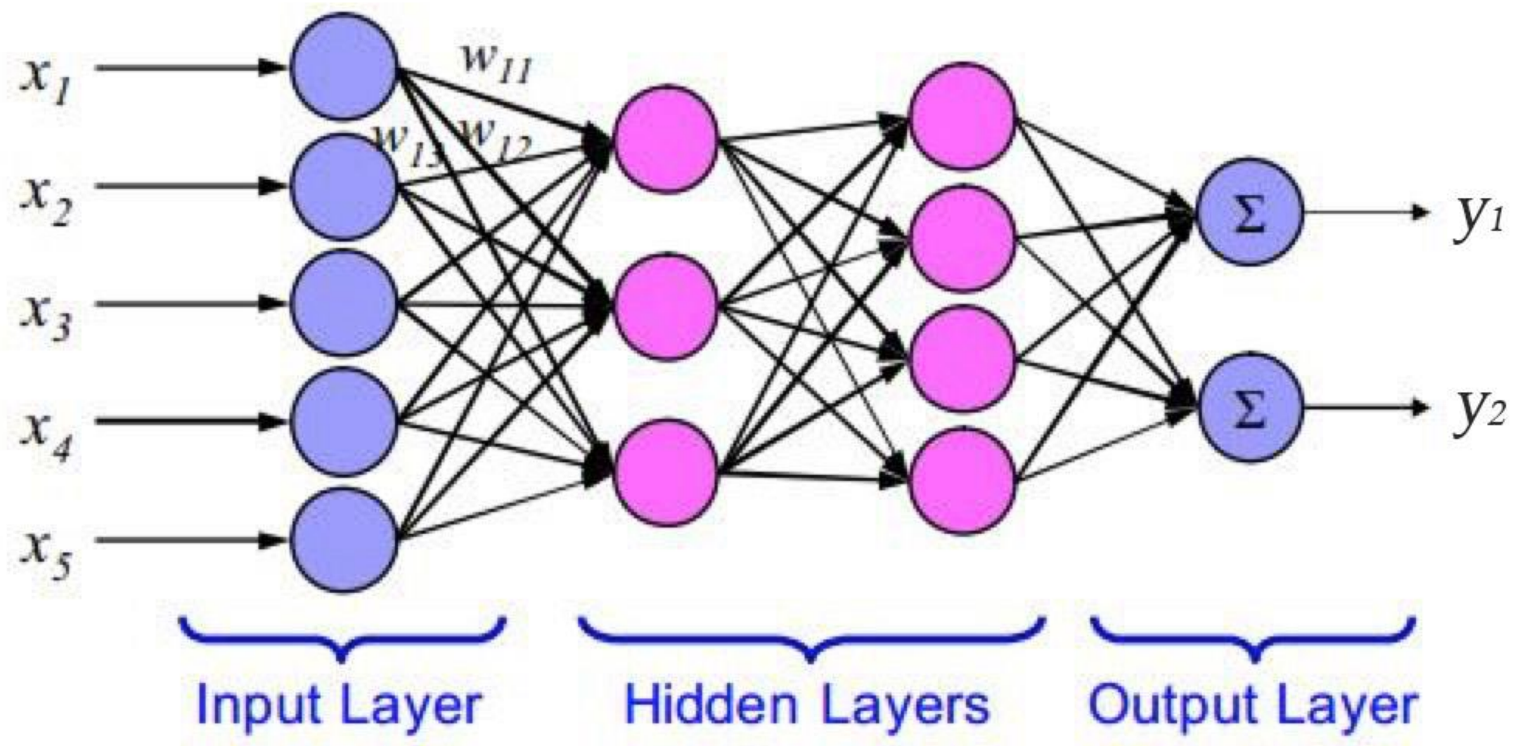

BP算法

t真实值，y预测值

$$E = \frac{1}{2}(t-y)^2$$

Delta学习规则

l代表第l层

$$\frac{\partial E}{\partial W^l} = -(X^l)^T \delta^l$$

W权值

$$\Delta W^l = -\eta \frac{\partial E}{\partial W^l} = \eta (X^l)^T \delta^l$$

学习率

BP算法结论

一层层向前传播

$$\delta^L = (t-y)f'(X^L W^L)$$

$$\delta^l = \delta^{l+1}(W^{l+1})^T f'(X^l W^l)$$

δ^l第l层学习信号
δ^L输出层学习信号
W^l第l-l+1层权值
X^l第l层的输入信号

BP算法

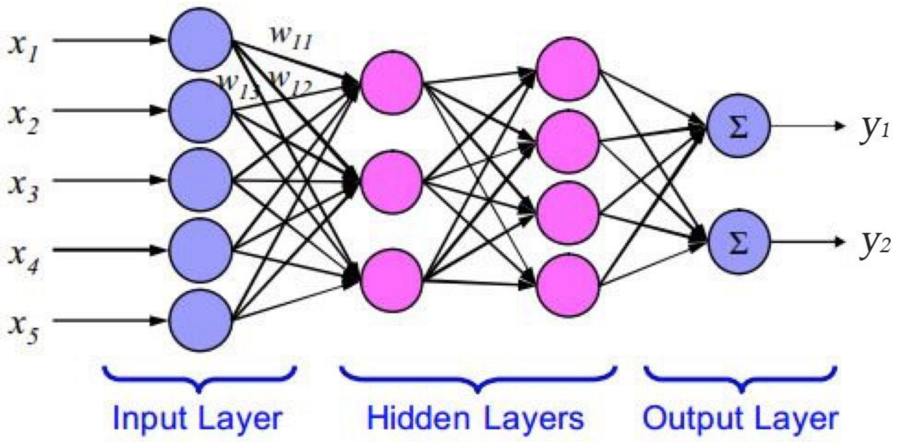

$$\Delta W^{l3} = -\eta\delta^{l3}X^{l3} = \eta(t-y)f'\left(X^{l3}W^{l3}\right)X^{l3}$$

$$\delta^{l3} = (t-y)f'(X^{l3}W^{l3})$$

$$\Delta W^{l2} = -\eta\delta^{l2}X^{l2} = \eta\delta^{l3}\left(W^{l3}\right)^T f'(X^{l2}W^{l2})X^{l2}$$

$$\delta^{l2} = \delta^{l3}\left(W^{l3}\right)^T f'\left(X^{l2}W^{l2}\right)$$

$$\Delta W^{l1} = -\eta\delta^{l1}X^{l1} = \eta\delta^{l2}\left(W^{l2}\right)^T f'\left(X^{l1}W^{l1}\right)X^{l1}$$

$$\delta^{l1} = \delta^{l2}\left(W^{l2}\right)^T f'\left(X^{l1}W^{l1}\right)$$

Sigmoid函数

激活函数

$$f(x)=\frac{1}{1+e^{-x}}$$

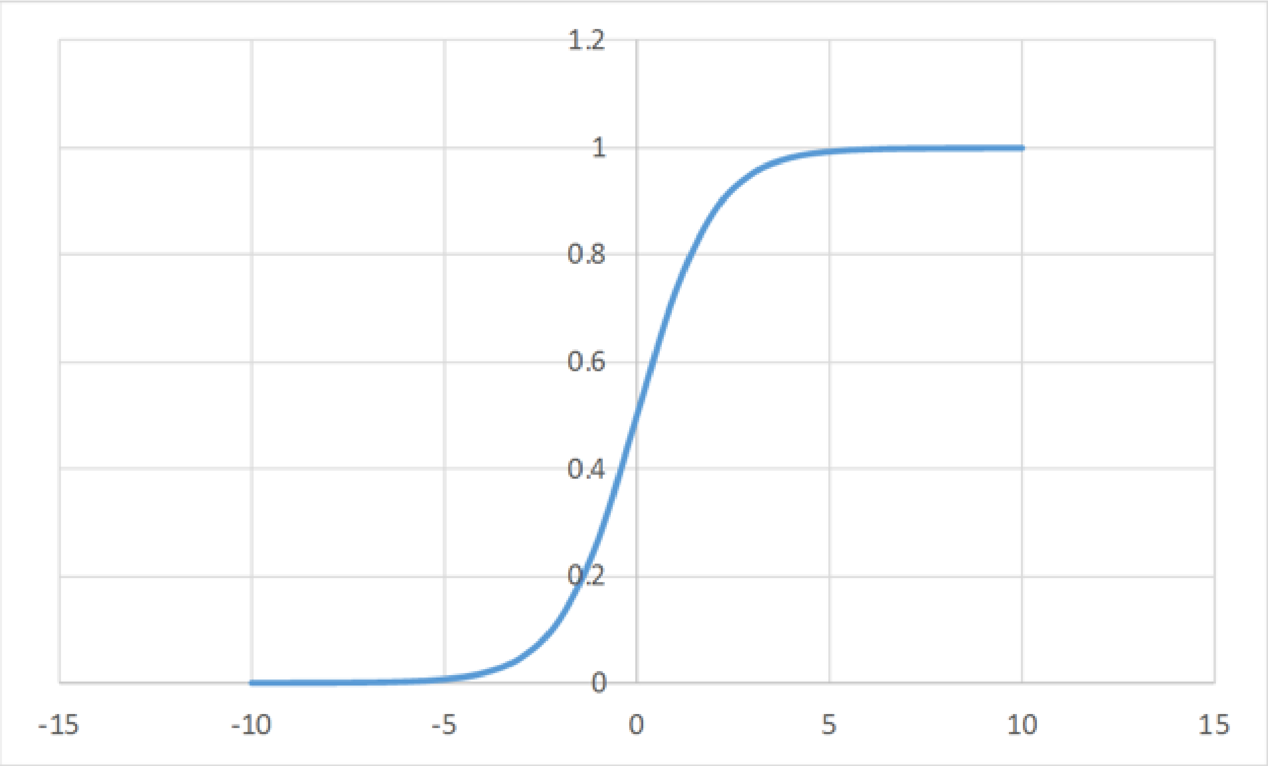

Tanh函数和Softsign函数

激活函数

Tanh函数：$\dfrac{e^x - e^{-x}}{e^x + e^{-x}}$　　Softsign函数：$\dfrac{x}{1+|x|}$

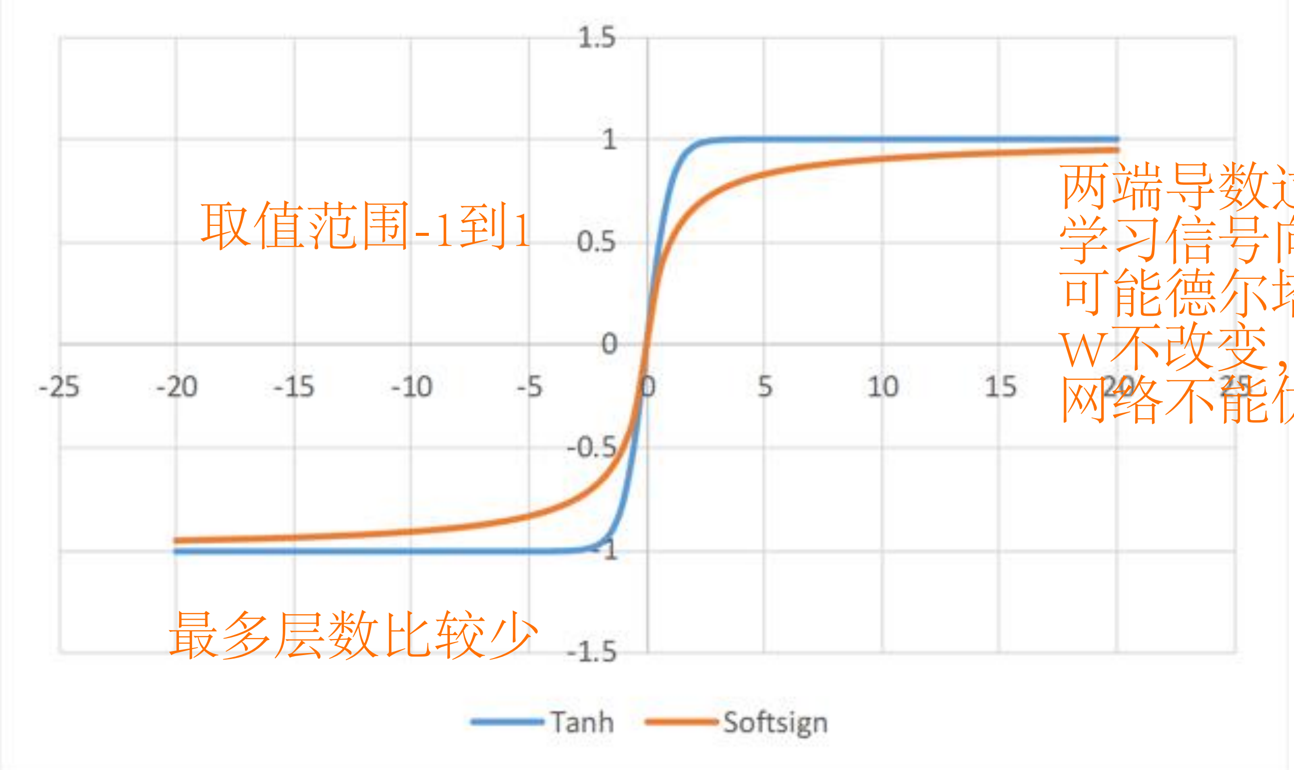

取值范围-1到1

最多层数比较少

两端导数过小，
学习信号向前传播越传越小，
可能德尔塔W=0
W不改变，权值不能改变
网络不能优化

ReLU函数

用的多

$$f(u) = \max(0, u)$$

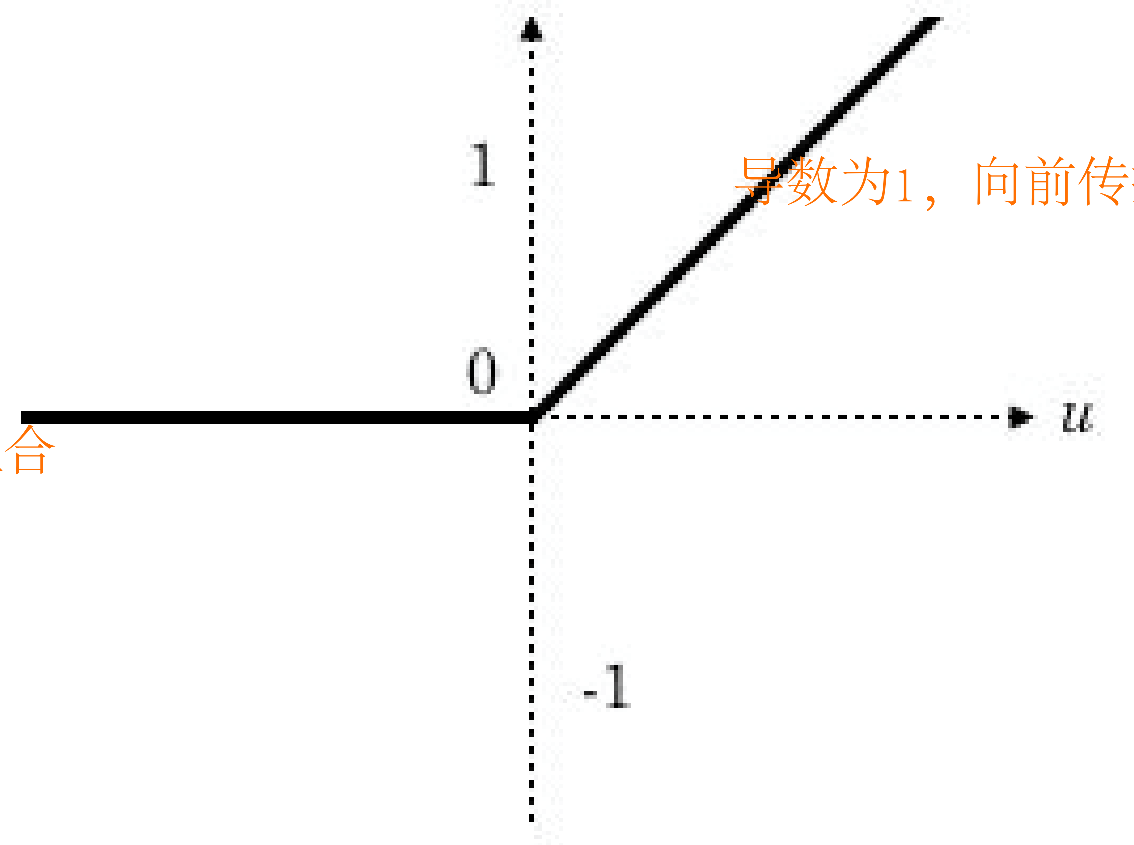

导数为1，向前传播学习信号不会衰减

画出边界是线段组合

混淆矩阵

假设有一个用来对猫（cats）、狗（dogs）、兔子（rabbits）进行分类的系统，混淆矩阵就是为了进一步分析性能而对该算法测试结果做出的总结。

		Predicted class		
		Cat	Dog	Rabbit
Actual class	Cat	5	3	0
	Dog	2	3	1
	Rabbit	0	2	11

在这个混淆矩阵中，实际有 8只猫，但是系统将其中3只预测成了狗。对于6条狗，其中有1条被预测成了兔子，2条被预测成了猫。